

# Ricochet

Système de recommandation d'articles — MVP

---

Approches testées · Fonctionnalités · Architecture cible · Démonstration

# Contexte

Ce qui est demandé, avec quelles données

- Proposer **5 articles** à chaque lecteur, pour l'inciter à lire davantage.
- Pas de données propriétaires : jeu public Globo.com — **2 988 181** clics, **322 897** lecteurs, **364 047** articles.
- **Contrainte majeure : le jeu est anonymisé.**
  - aucun titre, aucun texte : un article n'est qu'un vecteur de 250 dimensions et un identifiant ;
  - aucune note, aucun avis : seulement des clics, donc un signal implicite ;
  - conséquence — tout se fait sans lire le contenu, et l'interface ne peut afficher que des identifiants.

# Partie 1 — Les cinq approches testées


10 minutes · comment chacune classe les articles

| Approche         | Principe                                 | Bibliothèque       |
|------------------|------------------------------------------|--------------------|
| Popularité       | articles les plus lus sur une fenêtre    | —                  |
| Contenu          | profil = moyenne des embeddings, cosinus | scikit-learn (ACP) |
| Collaboratif ALS | factorisation lecteur $\times$ article   | implicit           |
| Collaboratif SVD | prédiction de notes dérivées des clics   | Surprise           |
| Mixte            | combinaison sur les 5 places             | —                  |

La popularité sert de **référence à battre** : elle ne personnalise rien, donc toute approche plus complexe doit faire mieux qu'elle.

# Approche 1 — Filtrage par le contenu

## Similarité des embeddings d'articles



### Avantages

- fonctionne dès le 1<sup>er</sup> clic, sans ré-entraînement ;
- gère un article nouveau immédiatement (il a un vecteur) ;
- couverture du catalogue la plus large : **0,27 %** contre 0,003 % ;
- personnalisation **96 %**.

### Inconvénients

- précision faible : HitRate@5 = **0,0200** ;
- n'exploite pas l'intelligence collective ;
- sans restriction aux articles récents, propose des articles vieux de plusieurs années que personne ne lit.

## Approche 2 — Collaboratif ALS (implicit)

### Factorisation pour feedback implicite

- Traite toutes les cases vides comme des **négatifs pondérés** : formulation adaptée à des clics, pas à des notes.
- Réglages mesurés sur validation — les deux pointent dans le même sens :
  - fenêtre d'entraînement **72 h** (0,0200) plutôt que tout l'historique (0,0120) ;
  - **16 facteurs** latents (0,0345) plutôt que 100 (0,0125).
- **Moins de données, plus récentes, et un modèle plus petit** valent mieux qu'un gros modèle appris sur dix jours d'actualité.
- Résultat sur test :  $\text{HitRate@5} = \mathbf{0,0415}$ , personnalisation 95 %.

Limite structurelle : un article publié il y a deux heures n'a presque aucune co-lecture — le collaboratif ne peut pas le proposer.

## Approche 3 — Collaboratif SVD (Surprise)

Trois définitions de note, trois résultats

| Définition de la note                | HitRate@5 | Person. | Verdict                 |
|--------------------------------------|-----------|---------|-------------------------|
| Étoiles de l'article (log des clics) | 0,0000    | 12 %    | reproduit la popularité |
| Binaire + 1 négatif échantillonné    | 0,0080    | 46 %    | insuffisant             |
| Binaire + 4 négatifs échantillonnés  | 0,0755 *  | 34 %    | meilleure variante      |

- Même bibliothèque, même algorithme : c'est la **formulation du problème** qui change tout, pas l'outil.
- Les étoiles échouent parce que la note ne dépend que de l'article : le biais article capte tout le signal, et le modèle apprend « quels articles sont lus », pas « qui lit quoi ».
- \* mesuré sur validation ; ce réglage **ne s'est pas reproduit** sur le test (0,0160) — d'où l'utilité d'une période de test intacte.

# Comment nous avons su que les premiers chiffres étaient faux

Découpage temporel 60 / 20 / 20

- Première évaluation : modèles entraînés sur 100 % des données, puis évalués sur ces mêmes données. L'ALS affichait  $\text{HitRate@5} = 0,2300$ .
- Avec un découpage temporel correct, il tombe à **0,0250** — **un facteur 42**, invisible sans découpage.
- Temporel et non aléatoire : sur un flux d'actualité, un découpage aléatoire laisse le modèle apprendre des clics *postérieurs* à ceux qu'il doit prédire.
- Le réglage se fait sur la validation ; le test ne sert qu'à la mesure finale, une seule fois.



le temps s'écoule de gauche à droite — aucune fuite du futur vers le passé

## Résultat principal : la fraîcheur pèse plus que le modèle

Même algorithme, deux fenêtres de comptage

| Fenêtre de comptage des clics | Candidats | HitRate@5     |
|-------------------------------|-----------|---------------|
| 1 heure                       | 791       | <b>0,2190</b> |
| 6 heures                      | 2 657     | 0,1480        |
| 24 heures                     | 6 777     | 0,1060        |
| Tout l'historique (240 h)     | 29 118    | <b>0,0075</b> |

- **Facteur 250** entre la première et la dernière ligne, sans changer une ligne d'algorithme.
- Explication : **48 %** des articles lus pendant la période évaluée n'existaient pas encore pendant l'entraînement.
- Conséquence produit : recalculer la fenêtre en continu compte davantage que raffiner le modèle.



# Quatre critères, pas un seul

La précision seule désigne toujours la popularité

| Critère          | Ce qu'il mesure                      | Popularité | Contenu |
|------------------|--------------------------------------|------------|---------|
| HitRate@5        | un article recommandé a été lu       | 0,2525     | 0,0200  |
| Couverture       | part du catalogue exposée            | 0,003 %    | 0,27 %  |
| Personnalisation | différence entre deux listes         | 4 %        | 96 %    |
| Recall@5         | part du futur devinée (plafond 0,76) | 0,0555     | 0,0034  |

- La popularité est 12 fois plus précise, mais expose **11 articles sur 364 047** : un éditeur y perd son catalogue.
- C'est le quatrième critère qui a **disqualifié le SVD sur étoiles** : personnalisation 12 %, soit *moins* que la popularité — il la reproduisait en plus grossier.

# Résultat final sur la période de test

Chaque approche dans sa meilleure configuration

| Configuration                           | HitRate@5     | Couverture     | Person. |
|-----------------------------------------|---------------|----------------|---------|
| Popularité 1 h                          | <b>0,2525</b> | 0,003 %        | 4 %     |
| <b>Mixte : 4 populaires + 1 contenu</b> | <b>0,2500</b> | 0,116 %        | 22 %    |
| ALS (72 h, 16 facteurs)                 | 0,0415        | 0,015 %        | 95 %    |
| Contenu (vivier 6 h)                    | 0,0200        | <b>0,268 %</b> | 96 %    |
| SVD Surprise (binaire + négatifs)       | 0,0160        | 0,010 %        | 53 %    |

- Retenu : **4 populaires (1 h) + 1 contenu**. La place accordée au contenu ne coûte rien en précision (0,2500 contre 0,2525, écart non significatif) et **multiplie la couverture par 38**.
- Une place donnée à l'ALS coûterait 3,7 % de précision pour un gain de couverture neuf fois plus faible : il reste disponible, mais n'est pas servi.


## Partie 2 — Les stratégies dans l'application

6 minutes · ce que l'utilisateur peut faire

- L'application expose les **cinq stratégies** : on bascule en direct et les listes diffèrent visiblement.
  - « Production » — 4 populaires (1 h) + 1 contenu : ce qui est servi ;
  - « Contenu », « ALS », « SVD Surprise », « Hybride » : pour comparaison.
- Une case « **Limitier aux articles récents** », activée par défaut : la décocher montre en direct l'effet mesuré en partie 1.
- Le nombre d'articles est réglable de 1 à 10.
- Chaque article affiche sa **note en étoiles** et son nombre de lecteurs — les seules informations réelles disponibles sur un jeu anonymisé.

# Un lecteur dont on ne sait rien

Le cas le plus fréquent sur un portail d'actualité



- **Cascade de repli** : région croisée avec la fraîcheur, puis fraîcheur, puis région, puis historique complet. Aucune requête ne renvoie de liste vide.
- La région est la seule information exploitable sur un lecteur inconnu : 27 régions retenues, celles ayant assez de clics pour un classement.
- Dès le premier article lu, le profil de contenu prend le relais — **sans aucun ré-entraînement**.

# Inscrire un lecteur, voir son profil se former

En direct, sans ré-entraînement

- L'application permet d'**inscrire un lecteur**, de lui donner un profil de départ, puis de marquer des articles comme lus.
- À chaque lecture enregistrée les recommandations changent : le profil est la moyenne des vecteurs lus, recalculée à la demande.
- Un onglet **catalogue** (364 047 articles, quatre tris, filtre par note) permet de cliquer autre chose que les cinq suggestions —
  - sans lui, le lecteur ne pourrait cliquer que ce que le modèle propose déjà, et son profil ne ferait que se renforcer dans sa direction initiale.
- Côté service, l'historique est **transmis dans la requête** : le service recommande un lecteur qu'il ne connaît pas, sans conserver d'état.

# Publier un nouvel article

Disponible en minutes, sans ré-entraînement



- La projection ACP est sérialisée avec le catalogue (**51 Ko**) : sans elle, intégrer un article imposerait de réajuster l'ACP, donc de recalculer les 364 047 vecteurs existants.
- Vérifié : trois articles ajoutés reçoivent les identifiants 364047–364049 et **entrent immédiatement** dans le top-5 d'un lecteur proche.
- L'article n'a ni étoiles ni facteurs collaboratifs — il n'a aucun clic. Il est recommandé par le contenu, seul signal disponible à cet instant.

# Reproductibilité et garde-fous


Ce qui empêche une régression de partir en production

| Élément                     | Rôle                                                |
|-----------------------------|-----------------------------------------------------|
| Découpage temporel 60/20/20 | réglage sur validation, mesure sur test             |
| MLflow (SQLite)             | paramètres, métriques et commit git de chaque essai |
| Registre de modèles         | versions des artefacts, retour arrière possible     |
| <b>Porte de qualité</b>     | bloque la publication si HitRate@5 baisse de >10 %  |
| CI (GitHub Actions)         | 48 tests, cohérence des copies déployées            |

- La porte compare aux métriques de référence **versionnées dans le dépôt** ; la référence ne change que délibérément.
- Sans elle, un ré-entraînement dégradé se publierait sans alerte — c'est exactement ce qui est arrivé avec un chargeur d'artefacts incomplet, qui servait la popularité de tout l'historique **sans lever d'erreur**.

## Partie 3 — Architecture technique

2 minutes · un cœur, trois déploiements indépendants



- Même cœur de recommandation dans les trois : les copies déployées sont **générées**, et la CI vérifie qu'elles sont à jour.
- À l'inférence, aucune bibliothèque d'apprentissage : **numpy seul**. scikit-learn, implicit et Surprise ne servent qu'hors-ligne.
- Architecture 2 retenue pour le MVP : la Function lit les artefacts dans Blob Storage, sans API intermédiaire.



# Architecture cible

## Absorber les nouveaux articles et les nouveaux lecteurs

| Événement           | Traitement                                          | Latence    | Ré-entr. |
|---------------------|-----------------------------------------------------|------------|----------|
| Nouvel article      | embedding + projection ACP                          | minutes    | non      |
| Nouveau clic        | profil recalculé à la demande                       | temps réel | non      |
| Nouveau lecteur     | popularité, puis contenu au 1 extsuperscripser clic | temps réel | non      |
| Couverture collab.  | facteurs latents                                    | heures     | oui      |
| Dérive du catalogue | ré-ajustement de l'ACP                              | planifié   | oui      |

- **Seule la partie collaborative impose un ré-entraînement** ; les deux besoins immédiats sont couverts sans.
- Reste à construire : ingestion événementielle, store de profils, fenêtre glissante recalculée en continu, index de similarité pour l'échelle.

## Partie 4 — Démonstration

2 minutes · six gestes

1. Sélectionner un lecteur : 5 articles, avec étoiles et nombre de lecteurs.
2. Décocher « articles récents » : la liste change — **l'effet mesuré, en direct.**
3. Basculer sur « SVD Surprise » : autre classement, autre bibliothèque.
4. Parcourir le catalogue : cliquer un article hors des suggestions.
5. Inscrire un lecteur : il reçoit des recommandations immédiatement.
6. Le même appel sur Azure : 0,2 s, réponse identique au local.

Les articles n'ont ni titre ni texte : le jeu de données est anonymisé par sa source.

L'interface affiche identifiant, catégorie, longueur, date et note — les seules informations réelles disponibles.

# La fraîcheur pèse plus que le modèle

Facteur 250 sur la précision, mesuré sur découpage temporel.

Une place sur cinq accordée à la personnalisation ne coûte rien et multiplie par 38 la part du catalogue exposée.