

Ricochet

Système de recommandation d'articles — MVP

Approches testées · Fonctionnalités · Architecture cible · Démonstration

Contexte

Ce qui est demandé, avec quelles données

- Proposer **5 articles** à chaque lecteur, pour l'inciter à lire davantage.
- Pas de données propriétaires : jeu public Globo.com — **2 988 181** clics, **322 897** lecteurs, **364 047** articles.
- **Contrainte majeure : le jeu est anonymisé.**
 - aucun titre, aucun texte : un article n'est qu'un vecteur de 250 dimensions et un identifiant ;
 - aucune note, aucun avis : seulement des clics, donc un signal implicite ;
 - conséquence — tout se fait sans lire le contenu, et l'interface ne peut afficher que des identifiants.

Partie 1 — Les cinq approches testées


10 minutes · comment chacune classe les articles

Approche	Principe	Bibliothèque
Popularité	articles les plus lus sur une fenêtre	—
Contenu	profil = moyenne des embeddings, cosinus	scikit-learn (ACP)
Collaboratif ALS	factorisation lecteur $\times$ article	implicit
Collaboratif SVD	prédiction de notes dérivées des clics	Surprise
Mixte	combinaison sur les 5 places	—

La popularité sert de **référence à battre** : elle ne personnalise rien, donc toute approche plus complexe doit faire mieux qu'elle.

Approche 1 — Filtrage par le contenu

Similarité des embeddings d'articles



Avantages

- fonctionne dès le 1^{er} clic, sans ré-entraînement ;
- gère un article nouveau immédiatement (il a un vecteur) ;
- couverture du catalogue la plus large : **0,27 %** contre 0,003 % ;
- personnalisation **96 %**.

Inconvénients

- précision faible : HitRate@5 = **0,0200** ;
- n'exploite pas l'intelligence collective ;
- sans restriction aux articles récents, propose des articles vieux de plusieurs années que personne ne lit.

Approche 2 — Collaboratif ALS (implicit)

Factorisation pour feedback implicite

- Traite toutes les cases vides comme des **négatifs pondérés** : formulation adaptée à des clics, pas à des notes.
- Réglages mesurés sur validation — les deux pointent dans le même sens :
 - fenêtre d'entraînement **72 h** (0,0200) plutôt que tout l'historique (0,0120) ;
 - **16 facteurs** latents (0,0345) plutôt que 100 (0,0125).
- **Moins de données, plus récentes, et un modèle plus petit** valent mieux qu'un gros modèle appris sur dix jours d'actualité.
- Résultat sur test : $\text{HitRate@5} = \mathbf{0,0415}$, personnalisation 95 %.

Limite structurelle : un article publié il y a deux heures n'a presque aucune co-lecture — le collaboratif ne peut pas le proposer.

Approche 3 — Collaboratif SVD (Surprise)

Trois définitions de note, trois résultats

Définition de la note	HitRate@5	Person.	Verdict
Étoiles de l'article (log des clics)	0,0000	12 %	reproduit la popularité
Binaire + 1 négatif échantillonné	0,0080	46 %	insuffisant
Binaire + 4 négatifs échantillonnés	0,0755 *	34 %	meilleure variante

- Même bibliothèque, même algorithme : c'est la **formulation du problème** qui change tout, pas l'outil.
- Les étoiles échouent parce que la note ne dépend que de l'article : le biais article capte tout le signal, et le modèle apprend « quels articles sont lus », pas « qui lit quoi ».
- * mesuré sur validation ; ce réglage **ne s'est pas reproduit** sur le test (0,0160) — d'où l'utilité d'une période de test intacte.

Comment nous avons su que les premiers chiffres étaient faux

Découpage temporel 60 / 20 / 20

- Première évaluation : modèles entraînés sur 100 % des données, puis évalués sur ces mêmes données. L'ALS affichait $\text{HitRate@5} = 0,2300$.
- Avec un découpage temporel correct, il tombe à **0,0250** — **un facteur 42**, invisible sans découpage.
- Temporel et non aléatoire : sur un flux d'actualité, un découpage aléatoire laisse le modèle apprendre des clics *postérieurs* à ceux qu'il doit prédire.
- Le réglage se fait sur la validation ; le test ne sert qu'à la mesure finale, une seule fois.



le temps s'écoule de gauche à droite — aucune fuite du futur vers le passé

Résultat principal : la fraîcheur pèse plus que le modèle

Même algorithme, deux fenêtres de comptage

Fenêtre de comptage des clics	Candidats	HitRate@5
1 heure	791	0,2190
6 heures	2 657	0,1480
24 heures	6 777	0,1060
Tout l'historique (240 h)	29 118	0,0075

- **Facteur 250** entre la première et la dernière ligne, sans changer une ligne d'algorithme.
- Explication : **48 %** des articles lus pendant la période évaluée n'existaient pas encore pendant l'entraînement.
- Conséquence produit : recalculer la fenêtre en continu compte davantage que raffiner le modèle.

Quatre critères, pas un seul

La précision seule désigne toujours la popularité

Critère	Ce qu'il mesure	Popularité	Contenu
HitRate@5	un article recommandé a été lu	0,2525	0,0200
Couverture	part du catalogue exposée	0,003 %	0,27 %
Personnalisation	différence entre deux listes	4 %	96 %
Recall@5	part du futur devinée (plafond 0,76)	0,0555	0,0034

- La popularité est 12 fois plus précise, mais expose **11 articles sur 364 047** : un éditeur y perd son catalogue.
- C'est le quatrième critère qui a **disqualifié le SVD sur étoiles** : personnalisation 12 %, soit *moins* que la popularité — il la reproduisait en plus grossier.

Résultat final sur la période de test

Chaque approche dans sa meilleure configuration

Configuration	HitRate@5	Couverture	Person.
Popularité 1 h	0,2525	0,003 %	4 %
Mixte : 4 populaires + 1 contenu	0,2500	0,116 %	22 %
ALS (72 h, 16 facteurs)	0,0415	0,015 %	95 %
Contenu (vivier 6 h)	0,0200	0,268 %	96 %
SVD Surprise (binaire + négatifs)	0,0160	0,010 %	53 %

- Retenu : **4 populaires (1 h) + 1 contenu**. La place accordée au contenu ne coûte rien en précision (0,2500 contre 0,2525, écart non significatif) et **multiplie la couverture par 38**.
- Une place donnée à l'ALS coûterait 3,7 % de précision pour un gain de couverture neuf fois plus faible : il reste disponible, mais n'est pas servi.


Partie 2 — Les stratégies dans l'application

6 minutes · ce que l'utilisateur peut faire

- L'application expose les **cinq stratégies** : on bascule en direct et les listes diffèrent visiblement.
 - « Production » — 4 populaires (1 h) + 1 contenu : ce qui est servi ;
 - « Contenu », « ALS », « SVD Surprise », « Hybride » : pour comparaison.
- Une case « **Limitier aux articles récents** », activée par défaut : la décocher montre en direct l'effet mesuré en partie 1.
- Le nombre d'articles est réglable de 1 à 10.
- Chaque article affiche sa **note en étoiles** et son nombre de lecteurs — les seules informations réelles disponibles sur un jeu anonymisé.

Un lecteur dont on ne sait rien

Le cas le plus fréquent sur un portail d'actualité



- **Cascade de repli** : région croisée avec la fraîcheur, puis fraîcheur, puis région, puis historique complet. Aucune requête ne renvoie de liste vide.
- La région est la seule information exploitable sur un lecteur inconnu : 27 régions retenues, celles ayant assez de clics pour un classement.
- Dès le premier article lu, le profil de contenu prend le relais — **sans aucun ré-entraînement**.

Inscrire un lecteur, voir son profil se former

En direct, sans ré-entraînement

- L'application permet d'**inscrire un lecteur**, de lui donner un profil de départ, puis de marquer des articles comme lus.
- À chaque lecture enregistrée les recommandations changent : le profil est la moyenne des vecteurs lus, recalculée à la demande.
- Un onglet **catalogue** (364 047 articles, quatre tris, filtre par note) permet de cliquer autre chose que les cinq suggestions —
 - sans lui, le lecteur ne pourrait cliquer que ce que le modèle propose déjà, et son profil ne ferait que se renforcer dans sa direction initiale.
- Côté service, l'historique est **transmis dans la requête** : le service recommande un lecteur qu'il ne connaît pas, sans conserver d'état.

Publier un nouvel article

Disponible en minutes, sans ré-entraînement



- La projection ACP est sérialisée avec le catalogue (**51 Ko**) : sans elle, intégrer un article imposerait de réajuster l'ACP, donc de recalculer les 364 047 vecteurs existants.
- Vérifié : trois articles ajoutés reçoivent les identifiants 364047–364049 et **entrent immédiatement** dans le top-5 d'un lecteur proche.
- L'article n'a ni étoiles ni facteurs collaboratifs — il n'a aucun clic. Il est recommandé par le contenu, seul signal disponible à cet instant.

Reproductibilité et garde-fous


Ce qui empêche une régression de partir en production

Élément	Rôle
Découpage temporel 60/20/20	réglage sur validation, mesure sur test
MLflow (SQLite)	paramètres, métriques et commit git de chaque essai
Registre de modèles	versions des artefacts, retour arrière possible
Porte de qualité	bloque la publication si HitRate@5 baisse de >10 %
CI (GitHub Actions)	48 tests, cohérence des copies déployées

- La porte compare aux métriques de référence **versionnées dans le dépôt** ; la référence ne change que délibérément.
- Sans elle, un ré-entraînement dégradé se publierait sans alerte — c'est exactement ce qui est arrivé avec un chargeur d'artefacts incomplet, qui servait la popularité de tout l'historique **sans lever d'erreur**.

Partie 3 — Architecture technique

2 minutes · un cœur, trois déploiements indépendants



- Même cœur de recommandation dans les trois : les copies déployées sont **générées**, et la CI vérifie qu'elles sont à jour.
- À l'inférence, aucune bibliothèque d'apprentissage : **numpy seul**. scikit-learn, implicit et Surprise ne servent qu'hors-ligne.
- Architecture 2 retenue pour le MVP : la Function lit les artefacts dans Blob Storage, sans API intermédiaire.
- Deux accès à Blob : **binding** sur les 23 Ko de fraîcheur — relus à chaque appel, donc mise à jour horaire extbfsans redémarrage — et SDK avec cache sur les 254 Mo d'artefacts lourds, où le binding coûterait 40imes plus par requête.

Architecture cible

Absorber les nouveaux articles et les nouveaux lecteurs

Événement	Traitement	Latence	Ré-entr.
Nouvel article	embedding + projection ACP	minutes	non
Nouveau clic	profil recalculé à la demande	temps réel	non
Nouveau lecteur	popularité, puis contenu au 1 ^{er} clic	temps réel	non
Couverture collab.	facteurs latents	heures	oui
Dérive du catalogue	ré-ajustement de l'ACP	planifié	oui

- **Seule la partie collaborative impose un ré-entraînement** ; les deux besoins immédiats sont couverts sans.
- Reste à construire : ingestion événementielle, store de profils, fenêtre glissante recalculée en continu, index de similarité pour l'échelle.

Partie 4 — Démonstration

2 minutes · six gestes

1. Sélectionner un lecteur : 5 articles, avec étoiles et nombre de lecteurs.
2. Décocher « articles récents » : la liste change — **l'effet mesuré, en direct.**
3. Basculer sur « SVD Surprise » : autre classement, autre bibliothèque.
4. Parcourir le catalogue : cliquer un article hors des suggestions.
5. Inscrire un lecteur : il reçoit des recommandations immédiatement.
6. Le même appel sur Azure : 0,2 s, réponse identique au local.

Les articles n'ont ni titre ni texte : le jeu de données est anonymisé par sa source.

L'interface affiche identifiant, catégorie, longueur, date et note — les seules informations réelles disponibles.

La fraîcheur pèse plus que le modèle

Facteur 250 sur la précision, mesuré sur découpage temporel.

Une place sur cinq accordée à la personnalisation ne coûte rien et multiplie par 38 la part du catalogue exposée.