

Ricochet

Système de recommandation d'articles — MVP

Approches testées · Fonctionnalités · Architecture cible · Démonstration

Contexte

Ce qui est demandé, avec quelles données

- Proposer **5 articles** à chaque lecteur, pour l'inciter à lire davantage.
- Pas de données propriétaires : jeu public Globo.com — **2 988 181** clics, **322 897** lecteurs, **364 047** articles.
- **Contrainte majeure : le jeu est anonymisé.**
 - aucun titre, aucun texte : un article n'est qu'un vecteur de 250 dimensions et un identifiant ;
 - aucune note, aucun avis : seulement des clics, donc un signal implicite ;
 - conséquence — tout se fait sans lire le contenu, et l'interface ne peut afficher que des identifiants.

Partie 1 — Les cinq approches testées


10 minutes · comment chacune classe les articles

Approche	Principe	Bibliothèque
Popularité	articles les plus lus sur une fenêtre	—
Contenu	profil = moyenne des embeddings, cosinus	scikit-learn (ACP)
Collaboratif ALS	factorisation lecteur $\times$ article	implicit
Collaboratif SVD	prédiction de notes dérivées des clics	Surprise
Mixte	combinaison sur les 5 places	—

La popularité sert de **référence à battre** : elle ne personnalise rien, donc toute approche plus complexe doit faire mieux qu'elle.

Approche 1 — Filtrage par le contenu

Similarité des embeddings d'articles



Avantages

- fonctionne dès le 1^{er} clic, sans ré-entraînement ;
- gère un article nouveau immédiatement (il a un vecteur) ;
- couverture du catalogue la plus large : **0,27 %** contre 0,003 % ;
- personnalisation **96 %**.

Inconvénients

- précision faible : HitRate@5 = **0,0200** ;
- n'exploite pas l'intelligence collective ;
- sans restriction aux articles récents, propose des articles vieux de plusieurs années que personne ne lit.

Approche 2 — Collaboratif ALS (implicit)

Factorisation pour feedback implicite

- Traite toutes les cases vides comme des **négatifs pondérés** : formulation adaptée à des clics, pas à des notes.
- Deux réglages balayés **séparément** sur validation : la fenêtre d'entraînement (72 h : 0,0200 contre 0,0175 à 24 h) puis le nombre de facteurs (16 : 0,0345 contre 0,0175 à 50).
- Combiner les deux gagnants — 72 h et 16 facteurs — paraissait évident. Le balayage **croisé** dit le contraire :
 - 24 h + 16 facteurs : **0,0345** — retenu ;
 - 72 h + 16 facteurs : **0,0110** — la pire des quatre.
- Un modèle à 16 facteurs a besoin d'un signal *dense* ; élargir à 72 h dilue les co-lectures et le prive de cette densité. Les réglages **interagissent** : on ne juxtapose pas des optima partiels.
- Résultat sur test, configuration retenue : $\text{HitRate@5} = \mathbf{0,0415}$, personnalisation 95 %.

Limite structurelle : un article publié il y a deux heures n'a presque aucune co-lecture — le collaboratif ne peut pas le proposer.

Approche 3 — Collaboratif SVD (Surprise)

Trois définitions de note, trois résultats

Définition de la note	HitRate@5	Person.	Verdict
Étoiles de l'article (log des clics)	0,0015	23 %	ne classe pas
Binaire + 1 négatif échantillonné	0,0080	46 %	insuffisant
Binaire + 4 négatifs échantillonnés	0,0815 *	34 %	meilleure variante

- Même bibliothèque, même algorithme : c'est la **formulation du problème** qui change tout, pas l'outil.
- Les étoiles échouent parce que la note ne dépend que de l'article : le biais article capte tout le signal, et le modèle apprend « quels articles sont lus », pas « qui lit quoi ».
- Les trois lignes sont mesurées sur la **validation**. Sur le test, la meilleure variante retombe à **0,0220** — un facteur 3,7. Le réglage **ne s'est pas reproduit**, et c'est ce qu'une période de test intacte sert à révéler.

Comment nous avons su que les premiers chiffres étaient faux

Découpage temporel 60 / 20 / 20


- Première évaluation : ALS entraîné sur 100 % des clics, puis mesuré en retirant le dernier clic de chaque lecteur — un clic que le modèle avait déjà vu. HitRate@5 = **0,2415**.
- Avec un découpage temporel correct, il tombe à **0,0415** — **un facteur 5,8** de précision imaginaire, invisible sans découpage.
- La popularité, elle, ne profite pas de la fuite : son classement ne dépend pas du lecteur. Seuls les modèles *personnalisés* peuvent recopier ce qu'ils ont appris d'un lecteur.
- Temporel et non aléatoire : sur un flux d'actualité, un découpage aléatoire laisse le modèle apprendre des clics *postérieurs* à ceux qu'il doit prédire.
- Le réglage se fait sur la validation ; le test ne sert qu'à la mesure finale, une seule fois.



le temps s'écoule de gauche à droite — aucune fuite du futur vers le passé

Résultat principal : la fraîcheur pèse plus que le modèle

Le résultat le plus important de l'évaluation



- **Facteur 42** entre la première et la dernière barre, sans changer une ligne d'algorithme.
- Explication : **48 %** des articles lus pendant la période évaluée n'existaient pas encore pendant l'entraînement.
- Conséquence produit : recalculer la fenêtre en continu compte davantage que raffiner le modèle.

Quatre critères, pas un seul


La précision seule désigne toujours la popularité

Critère	Ce qu'il mesure	Popularité	Contenu
HitRate@5	un article recommandé a été lu	0,2525	0,0200
Couverture	part du catalogue exposée	0,003 %	0,27 %
Personnalisation	différence entre deux listes	4 %	96 %
Recall@5	part du futur devinée (plafond 0,76)	0,0555	0,0034

- La popularité est 12 fois plus précise, mais expose **11 articles sur 364 047** : un éditeur y perd son catalogue.
- Aucun critère ne sauve le **SVD sur étoiles** : HitRate nul et personnalisation 12 %, contre 96 % pour le contenu. Il ne trouve rien et ne distingue presque pas les lecteurs — parce que sa note ne dépend que de l'article.

Résultat final sur la période de test

Chaque approche dans sa meilleure configuration



- Retenu : **4 populaires (1 h) + 1 contenu** — la place donnée au contenu ne coûte rien en précision (écart non significatif) et **multiplie la couverture par 38**.
- Les deux collaboratifs restent en bas à gauche : un ordre de grandeur moins précis que la popularité et vingt fois moins couvrants que le contenu. Disponibles dans l'application, ils ne sont pas servis.

Partie 2 — Les stratégies dans l'application

6 minutes · le même lecteur, une seule case décochée

Fraîcheur activée — fenêtre 1 h

5 article(s) recommandé(s) — mix

1. Article #277107 ★★★★★ (9 373 lecteurs) — catégorie 409 · 144 mots · publié le 16/10/2017
2. Article #336254 ★★★★★ (10 627 lecteurs) — catégorie 437 · 170 mots · publié le 16/10/2017
3. Article #157478 ★★★★★ (5 888 lecteurs) — catégorie 281 · 259 mots · publié le 16/10/2017
4. Article #352979 ★★★★★ (3 784 lecteurs) — catégorie 442 · 169 mots · publié le 16/10/2017
5. Article #284220 ★ (9 lecteurs) — catégorie 412 · 224 mots · publié le 17/10/2017

- À gauche, le 16/10 et 3 784 à 10 627 lecteurs ; à droite, le 25/09 et un article lu par **une personne** — **le facteur 42, rendu visible**.
- Cinquième place à gauche : #284220 du **17/10**, neuf lecteurs. C'est la place du contenu, et la popularité ne la trouverait jamais.


Fraîcheur désactivée — tout le catalogue

5 article(s) recommandé(s) — mix

1. Article #4907 ★★★ (603 lecteurs) — catégorie 2 · 210 mots · publié le 09/10/2017
2. Article #257291 ★★★★★ (8 119 lecteurs) — catégorie 391 · 205 mots · publié le 04/10/2017
3. Article #2303 ★★★ (111 lecteurs) — catégorie 1 · 204 mots · publié le 02/10/2017
4. Article #235230 ★★★★★ (9 123 lecteurs) — catégorie 375 · 262 mots · publié le 03/10/2017
5. Article #160997 ★ (1 lecteurs) — catégorie 281 · 241 mots · publié le 25/09/2017

Un lecteur dont on ne sait rien

Le cas le plus fréquent sur un portail d'actualité



- **Cascade de repli** : région croisée avec la fraîcheur, puis fraîcheur, puis région, puis historique complet. Aucune requête ne renvoie de liste vide.
- La région est la seule information exploitable sur un lecteur inconnu : 27 régions retenues, celles ayant assez de clics pour un classement.
- Dès le premier article lu, le profil de contenu prend le relais — **sans aucun ré-entraînement**.

Inscrire un lecteur, voir son profil se former

En direct, sans ré-entraînement

Inscription — région optionnelle

Inscrire un nouveau client

Le jeu de données est anonymisé : les articles n'ont ni titre ni texte, seulement un identifiant, une date et une longueur.
Un nouveau client démarre donc sur les articles les plus lus, puis son profil se construit à mesure qu'il marque des articles comme lus.

Nom du client

ex. Camille Martin

Région du lecteur (optionnel)

— inconnue (popularité mondiale) —

Articles déjà lus (optionnel)

Catalogue — 364 047 articles

Trier par

Les plus lus

Note minimale (★)

0



Page (sur 2,301)

1

46,003 article(s) — affichage 1–20. Cliquez « Lu » sur ce que le client a lu.

Article #233688 ★★★★★ (11 084 lecteurs) — catégorie 375 · 210 mots · publié le 11/10/2017

Article #235854 ★★★★★ (10 815 lecteurs) — catégorie 375 · 162 mots · publié le 11/10/2017

Article #159762 ★★★★★ (10 700 lecteurs) — catégorie 281 · 258 mots · publié le 04/10/2017

- Recommandations **immédiates** à l'inscription ; à chaque article lu, le profil — moyenne des vecteurs lus — est recalculé à la demande, **sans ré-entraînement**.
- Le catalogue a une raison d'être : sans lui, le lecteur ne cliquerait que ce que le modèle propose déjà, et son profil ne ferait que se renforcer.
- L'historique est **transmis dans la requête** : la Fonction recommande un lecteur qu'elle ne connaît pas, sans état.

Publier un nouvel article

Disponible en minutes, sans ré-entraînement



- La projection ACP est sérialisée avec le catalogue (**51 Ko**) : sans elle, intégrer un article imposerait de réajuster l'ACP, donc de recalculer les 364 047 vecteurs existants.
- Vérifié : trois articles ajoutés reçoivent les identifiants 364047–364049 et **entrent immédiatement** dans le top-5 d'un lecteur proche.
- L'article n'a ni étoiles ni facteurs collaboratifs — il n'a aucun clic. Il est recommandé par le contenu, seul signal disponible à cet instant.

Reproductibilité et garde-fous


Ce qui empêche une régression de partir en production

Élément	Rôle
Découpage temporel 60/20/20	réglage sur validation, mesure sur test
MLflow (SQLite)	paramètres, métriques et commit git de chaque essai
Registre de modèles	versions des artefacts, retour arrière possible
Porte de qualité	bloque la publication si HitRate@5 baisse de >10 %
CI (GitHub Actions)	52 tests, cohérence des copies déployées

- La porte compare aux métriques de référence **versionnées dans le dépôt** ; la référence ne change que délibérément.
- Sans elle, un ré-entraînement dégradé se publierait sans alerte — c'est exactement ce qui est arrivé avec un chargeur d'artefacts incomplet, qui servait la popularité de tout l'historique **sans lever d'erreur**.

Partie 3 — Architecture technique

2 minutes · un cœur, trois déploiements indépendants



- Même cœur de recommandation dans les trois : les copies déployées sont **générées**, et la CI vérifie qu'elles sont à jour.
- À l'inférence, aucune bibliothèque d'apprentissage : **numpy seul**. scikit-learn, implicit et Surprise ne servent qu'hors-ligne.
- Architecture 2 retenue pour le MVP : la Function lit Blob Storage sans API intermédiaire, avec **deux accès selon la cadence** — *binding* sur les 23 Ko de fraîcheur, relus à chaque appel donc mise à jour horaire sans redémarrage ; SDK avec cache sur les 254 Mo d'artefacts lourds, où le binding coûterait 40 fois plus par requête.

Architecture cible

Absorber les nouveaux articles et les nouveaux lecteurs

Événement	Traitement	Latence	Ré-entr.
Nouvel article	embedding + projection ACP	minutes	non
Nouveau clic	profil recalculé à la demande	temps réel	non
Nouveau lecteur	popularité, puis contenu au 1 ^{er} clic	temps réel	non
Couverture collab.	facteurs latents	heures	oui
Dérive du catalogue	ré-ajustement de l'ACP	planifié	oui

- **Seule la partie collaborative impose un ré-entraînement** ; les deux besoins immédiats sont couverts sans.
- Reste à construire : ingestion événementielle, store de profils, fenêtre glissante recalculée en continu, index de similarité pour l'échelle.

Partie 4 — Démonstration

2 minutes · six gestes

1. Sélectionner un lecteur : 5 articles, avec étoiles et nombre de lecteurs.
2. Décocher « articles récents » : la liste change — **l'effet mesuré, en direct.**
3. Basculer sur « SVD Surprise » : autre classement, autre bibliothèque.
4. Parcourir le catalogue : cliquer un article hors des suggestions.
5. Inscrire un lecteur : il reçoit des recommandations immédiatement.
6. Le même appel sur Azure : 0,2 s, réponse identique au local.

Les articles n'ont ni titre ni texte : le jeu de données est anonymisé par sa source.

L'interface affiche identifiant, catégorie, longueur, date et note — les seules informations réelles disponibles.

La fraîcheur pèse plus que le modèle

Facteur 42 sur la précision, mesuré sur la période de test.

Une place sur cinq accordée à la personnalisation ne coûte rien et multiplie par 38 la part du catalogue exposée.